



사용자가 쓰는 서비스를 끝까지 운영한 과정

PeroChat · 웹 기반 AI 캐릭터 채팅 서비스

프로젝트 요약 학교 연구과제의 VRM 과 LLM 아이디어를 가입, 결제, 배포, 운영이 가능한 서비스로 확장했습니다. 기능 수보다 실제 문제를 어떻게 판단하고 해결했는지 세 가지 사례로 설명합니다.



캐릭터 허브



캐릭터 프로필

지원 직무	안유찬 · Full-Stack Developer
프로젝트	PeroChat · 2025.05-현재 · 완전한 개인 프로젝트
운영 상태	실서비스 운영 · 실제 가입자 약 100 명 · 앱 배포 채널 테스트 중
연락처	ultrauc123@gmail.com · github.com/yuchanahn · personaxi.com


무엇을 만들었는가보다,
왜 그렇게 판단했는가를 설명합니다.

연구과제를 실제 사용자가 들어오는 서비스로 확장

기획부터 출시 이후의 운영까지 혼자 맡았습니다.

청강문화산업대학교 전공심화 과정에서 VRM 캐릭터와 LLM 을 결합한 웹 채팅을 연구과제로 시작했습니다. 당시에는 LLM 응답에 감정 태그를 포함해 표정과 애니메이션을 선택했고, 이후 2D·Live2D·VRM 과 사용자 제작 기능을 갖춘 PeroChat 으로 확장했습니다.

현재 PeroChat 은 한국어·영어·일본어 UI 를 제공하며 테스트 계정 없이 약 100 명이 가입했습니다. PayPal·PortOne·Google Play 의 실제 소액 결제를 확인했고, Google Play 와 Apps in Toss 배포는 테스트 단계입니다. 수익은 아직 0 원이며 초기 수익화 검증 단계입니다.



캐릭터 제작 도구



Live2D 채팅

제가 직접 맡은 범위

제품	문제 정의, 사용자 흐름, 가격 정책, 약관과 권리 고지
프론트엔드	SvelteKit·TypeScript, 반응형 UI, PWA, VRM·Live2D
백엔드 / AI	Go API, 인증·권한, 결제, PostgreSQL·Redis, LLM Gateway
배포 / 운영	Oracle Cloud, Coolify, GitHub Pages, 관리자 도구, 사용자 유입 활동

이 문서의 범위 초기에 검토한 경매·방송 기능은 아직 개발하지 않았습니다. 구현된 기능, 실제로 검증한 흐름, 남아 있는 한계를 구분해 적었습니다.

처음의 선택보다, 유지와 분리의 이유

비용과 변경 범위가 판단 기준이었습니다.



기술 선택의 실제 이유

Svelte 추천으로 시작해 유지 - 처음에는 빠르게 만들 수 있다는 주변 개발자의 추천이었습니다. 이후 문법이 익숙해졌고, 현재 요구사항에서 React 전환 이점보다 변경 비용이 크다고 판단했습니다.

CSR SSR 에서 정적 빌드로 전환 - 로그인 이후 상호작용이 중심이라 SSR 이점이 작았습니다. GitHub Pages 로 비용을 없애고 Android-iOS 패키징과 독립 API 구성을 단순화했습니다.

Go 제품 규칙을 API 서버에 집중 - 문법과 고루틴에 익숙했고, 명시적 오류 처리와 단일 바이너리 배포가 개인 운영 서버에 잘 맞았습니다.

Oracle / Coolify 가격과 운영 부담을 우선 - 저렴한 인스턴스를 선택하고 Git 연동, 환경 변수, HTTPS, 로그, 배포 관리를 Coolify 에 맡겨 무중단 배포 체계를 직접 만들지 않았습니다.


Redis: 수치보다 판단을 먼저 남긴 사례

문제	1,000 명 생성·편집과 1,000 명 조회 시나리오에서 목록·태그 조회가 PostgreSQL 에 집중
판단	캐릭터 목록과 필터 결과는 조회가 많고 변경 빈도는 상대적으로 낮음
구조	조회 결과를 Redis 에 캐시하고 캐릭터 변경 시 관련 키만 무효화
복구 / 한계	PostgreSQL 을 원본으로 유지해 캐시 없이도 동작. 당시 전후 응답 지표는 보존하지 못함

공급자가 막혔을 때, 어디까지 자동 복구할 것인가

LLM Gateway 의 경계와 fallback 조건을 명시했습니다.

AI 채팅은 모델명, 요청 형식, 스트리밍 이벤트, quota 정책이 공급자마다 달랐습니다. 이 차이를 채팅 도메인 코드에 섞으면 모델을 바꿀 때마다 제품 API 까지 수정해야 하고, 한도 소진이 곧 전체 채팅 중단으로 이어집니다.



중복 응답을 피하기 위한 fallback 규칙

요청 전 실패	Gateway 연결·HTTP 요청이 실패하면 기본 Gemini 경로로 전환
출력 없음	Gateway 스트림이 아무 이벤트 없이 종료되면 기본 경로로 재요청
부분 출력 후 실패	이미 받은 문장과 fallback 결과가 겹치지 않도록 자동 재요청하지 않음
한도 처리	요청 전 quota 를 확인하고 pro/flash 별 활성 계정을 분리해 소진된 풀 안에서 회전

결과와 한계 공급자 경계를 제품 API 밖으로 옮기고, quota 소진 시 계정 회전과 기본 모델 fallback 이 가능해졌습니다. 다만 circuit breaker 는 아직 없으며, 부분 출력 이후의 장애는 중복 문장을 피하기 위해 현재 응답을 종료합니다.

결제 성공 화면보다, 재화가 한 번만 지급되는가


클라이언트를 신뢰하지 않고 공급자 상태를 다시 확인했습니다.

결제 버튼이 성공을 표시해도 서버는 금액, 구매자, 상품, 결제 상태를 다시 검증해야 합니다. 웹훅 재전송과 앱의 중복 요청까지 고려하지 않으면 같은 주문으로 재화가 여러 번 지급될 수 있습니다.




공급자별로 실제 구현한 검증

PortOne	웹훅 서명과 5 분 timestamp 검증, API 로 원본 결제 재조회, 금액·정책 불일치 시 자동 취소
PayPal	서버에서 capture 후 COMPLETED 상태, custom_id 의 사용자, 현재 가격 정책을 대조
Google Play	Publisher API 로 package-product-account·구매 상태를 확인하고 purchaseToken PK 와 order ID unique 로 중복 처리



Google Play 상품 선택




실제 소액 결제

검증 결과와 남은 위험 실제 소액 결제로 승인, 취소, 웹훅, 구매 상태 반영을 확인했습니다. Google Play 는 purchaseToken 삽입 성공 여부가 지급 gate 이지만, PortOne-PayPal 은 결제 기록과 재화 지급이 아직 하나의 DB 트랜잭션이 아닙니다. 다음 개선은 order/event key 의 최초 삽입 성공 시에만 ledger 를 생성하는 원자적 멍등 처리입니다.


iPhone Safari 에서 키보드가 화면 전체를 밀어냈다

Layout Viewport 와 Visual Viewport 의 차이를 직접 보정했습니다.

VRM-Live2D 채팅은 전체 화면 canvas 위에 입력창이 고정됩니다. iPhone Safari 와 PWA 에서는 가상 키보드가 열릴 때 보이는 영역만 줄어드는데, 100dvh 와 브라우저 스크롤이 함께 반응하면서 캐릭터 화면 전체가 위로 밀리고 입력창 위치도 흔들렸습니다.



iPhone형 Live2D 채팅



모바일 2D 채팅

재현 후 적용한 보정

높이 계산	<code>window.innerHeight - visualViewport.height - offsetTop</code> 으로 키보드가 차지한 영역 계산
이벤트	<code>visualViewport resize-scroll</code> 과 <code>input focusin-focusout</code> 을 함께 관찰
레이아웃	전체 canvas 대신 입력 wrapper 만 <code>keyboardHeight</code> 만큼 <code>translateY</code> , focus 는 <code>preventScroll</code> 사용
달힘 처리	키보드가 천천히 내려가는 기기에서 남는 차이를 <code>requestAnimationFrame</code> 최대 30 프레임 확인


판단 브라우저 전체 스크롤을 억지로 되돌리기보다, 실제로 변하는 Visual Viewport 를 상태로 다루고 이동 대상은 입력창으로 제한했습니다. `visualViewport` 가 없는 환경에서는 보정을 적용하지 않습니다.

한계 모바일 브라우저와 키보드 조합에 따라 동작이 달라 실제 기기 회귀 확인이 필요합니다. 현재 WebKit 자동 시각 회귀 테스트까지는 구축하지 못했습니다.

출시 후 반복되는 작업을 운영 도구로 흡수

사용자 화면 밖의 권한과 검증도 제품 범위로 보았습니다.

프롬프트를 바꿀 때마다 코드를 수정하거나 DB 를 직접 편집하면 실수 범위가 커집니다. 조합 결과와 적용 레이어를 미리 확인하고 런타임 검사를 통과한 설정만 실서비스에 반영하도록 별도 관리자 화면을 만들었습니다.



프롬프트	PromptKit 조합 미리보기, 모드별 결과 확인, 런타임 검사와 적용 상태 전환
사용자 / 보상	역할·플랜·상태·재화 조회, 지급 수량·만료 기간·사유와 처리 기록 관리
접근 통제	관리 화면은 로컬 실행. API 는 Supabase JWT, 서버 admin 역할 미들웨어, rate limit 적용
운영 범위	3 개 언어 UI, 약 100 명 가입, SNS 직접 홍보, 약관·개인정보·라이선스 문서 정비

혼자 운영하기 위한 인프라 선택

Frontend **GitHub Pages** - SSR 의 이점이 작아 정적 호스팅으로 프론트엔드 비용을 없앴습니다.

Compute / Deploy **Oracle Cloud + Coolify** - 저렴한 인스턴스에서 API·PostgreSQL·Redis 를 운영하고 배포·HTTPS·환경 변수·로그 관리를 한곳에 모았습니다.

Assets / Model **Supabase CDN + Hugging Face** - 리사이즈 썸네일 전달과 CPU 감정 분석 모델을 분리해 원본 전송과 별도 서버 비용을 줄였습니다.

운영에서 배운 것 배포 자체보다 결제 실패, 외부 API 한도, 권리 고지, 모바일 입력 문제를 처리하는 데 더 많은 시간이 들었습니다. 그래서 관리자 기능과 복구 경로도 사용자 기능과 같은 수준으로 다룹니다.

QuickBite: 실제 판매자가 바로 쓸 수 있는 주문 흐름

큰 구조보다 운영 속도와 사용자의 동선을 우선했습니다.

프로젝트 배경 교내에서 디저트를 판매하던 실제 사용자를 위해 메뉴 선택, 수령 시간 입력, 주문 접수와 판매자 관리를 한곳에 연결했습니다. 자체 도메인을 연결하고 Ubuntu 서버에서 실제 운영했습니다.

주문 정보·수령 시간 입력

주문 접수·결제 안내

문제에서 운영까지

문제	메신저 주문은 메뉴·옵션·수령 시간 확인과 주문 정리에 반복 작업이 많음
고객 흐름	재고 확인 → 메뉴·옵션 → 연락처·수령 시간 → 주문 확인
판매자 흐름	관리자 인증 후 주문·메뉴·가격·재고·판매 일정·계좌 정보 관리
저장 / 알림	SQLite 트랜잭션과 mutex 처리 후 Google Sheets 기록·Discord 신규 주문 알림
배포	SvelteKit Node adapter · Ubuntu · 자체 도메인 · 서버 배포 스크립트

선택과 결과 짧은 판매 기간과 소규모 사용자를 고려해 PostgreSQL 이나 복잡한 큐를 추가하지 않았습니다. 판매자가 바로 확인할 수 있는 Sheets 와 Discord 를 연결해 별도 교육 없이 운영 가능한 흐름을 우선했습니다.

한계 대규모 트래픽을 목표로 한 구조가 아니며 현재 저장소는 비공개입니다. 이 프로젝트는 실제 사용자 요구를 빠르게 제품과 운영 도구로 연결한 경험으로 제시합니다.

기능을 많이 만드는 개발자에서, 판단을 남기는 개발자로

현재의 강점과 부족한 부분을 함께 설명합니다.

게임 개발 경험에서 가져온 기반

Unreal / C++	멀티플레이 애니메이션 위치 보정, 공유 인벤토리 상태와 선점 권한 동기화
Unity / C#	상태 패턴 기반 로직, Google Sheets CSV 데이터 파이프라인, JSON 저장·복원
Networking	UDP ACK 신뢰성 실험, NAT 홉핑, 입력 예측과 롤백 데모

게임 개발에서 지연되는 통신, 여러 클라이언트가 공유하는 상태, 실패 후 복구 경로를 먼저 생각하는 습관을 얻었습니다. 이 관점은 PeroChat의 실시간 응답, 결제 상태, 캐릭터 런타임을 설계할 때 그대로 이어졌습니다.

AI 도구를 사용하는 방식

문서 해석, 초기 페이지 골격, 반복 작업, 영어·일본어 번역 초안과 누락 키 탐색에 AI 에이전트를 적극 사용했습니다. 다만 에이전트가 잘못된 가정으로 해매거나 실제 버그를 찾지 못한 경우도 있어 아키텍처 결정, 핵심 통합, 재현과 검증은 직접 통제했습니다.

작업 원칙 생성된 코드의 양보다 구조를 설명할 수 있는지, 실패했을 때 직접 고칠 수 있는지, 운영 중 어떤 위험이 남는지를 더 중요하게 봅니다.

다음 개선을 구체적으로 남깁니다

- Redis 부하 테스트에 P50-P95, 오류율, 캐시 적중률을 자동 수집해 전후 근거 보존
- PortOne·PayPal 결제 기록과 재화 ledger를 원자적 먹등 처리로 통합
- LLM·결제·모바일 입력 경로의 관측성, 통합 테스트, 회귀 테스트 강화

제가 기여하고 싶은 방식 제품과 코드베이스의 제약을 먼저 이해하고, 가장 단순하게 설명할 수 있는 해결책을 선택하겠습니다. 구현 완료가 아니라 배포 이후의 장애, 비용, 권한과 사용자 경험까지 확인하는 풀스택 개발자로 기여하고 싶습니다.

안유찬 · Full-Stack Developer

ultrauc123@gmail.com · github.com/yuchanahn · personaxi.com